

EST 526 Introducción a la Estadística No Paramétrica

Zayner Edin Rodríguez Flores

Postgrado en Edafología

Colegio de Postgraduados-Campus Montecillo

Tarea 2

Prueba de *Kruskal-Wallis*, Prueba de *Nemenyi*, Prueba de *Dunn*, ANOVA de una Vía, Prueba de *Friedman*, Prueba de *Ansari-Bradley*, Prueba de *Kolmogorov-Smirnov*, Parcelas Divididas con ARTools, Coeficientes de Correlación: *Pearson*, *Spearman*, *Kendall*

Para la realización de esta tarea los ejercicios se realizaron en el entorno RStudio para el lenguaje de programación R.

Problema 1

La siguiente tabla contiene información sobre la longitud de las hojas de plantas de la misma especie en cada uno de cuatro lugares pantanosos no urbanizados. En cada uno de estos, se seleccionaron aleatoriamente seis plantas.

Se seleccionaron al azar diez hojas de cada una de las plantas y la media de las diez mediciones (en centímetros) se registro para cada planta de cada uno de los lugares. Use la prueba H de Kruskal–Wallis para determinar si hay suficiente evidencia para afirmar que la distribución de las longitudes medias de las hojas difiere en localizaciones para al menos dos de los sitios. Use $\alpha = 0,05$ y encuentre el *p-value* aproximado.

Cuadro 1. Longitud media de las hojas de plantas de la misma especie en cuatro lugares distintos.

Localización	Longitud media de la hoja (cm.)					
1	5.7	6.3	6.1	6.0	5.8	6.2
2	6.2	5.3	5.7	6.0	5.2	5.5
3	5.4	5.0	6.0	5.6	4.0	5.2
4	3.7	3.2	3.9	4.0	3.5	3.6

- a) Establezca el Juego de hipótesis para probar si la longitud media de las hojas son similares entre localidades.

H_0 =La longitud de las hojas en los cuatro sitios es igual.

H_a =En al menos uno de los cuatro sitios la longitud de las hojas NO es igual.

- b) Realice una gráfica de caja (Boxplot)

```
# Boxplot #  
ggboxplot(dat_pro1, x = "loc", y = "long",
```

```

xlab= "Localidad",ylab="Longitud media de las hojas",
color = "loc", palette = "jco",
add = "jitter", facet.by = NULL, ggtheme = theme_pubr())

```

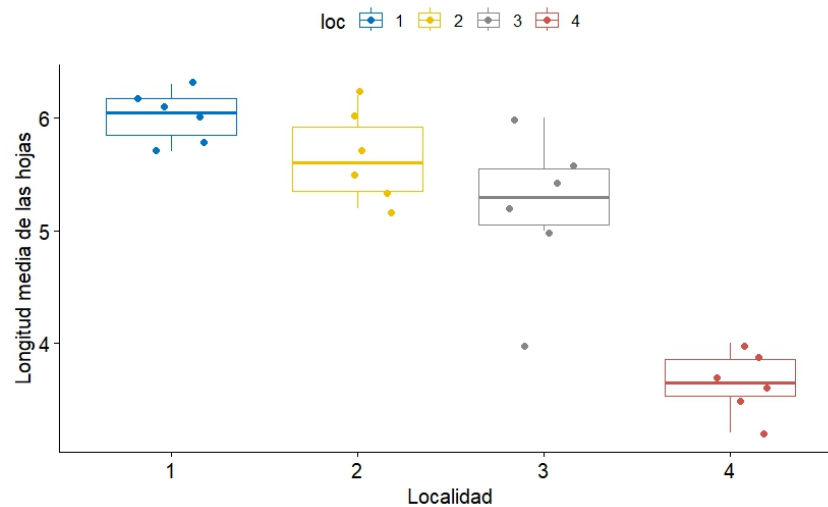


Figura 1. Longitud media de la hoja en cuatro diferentes localidades.

Resultando:

- c) Utilice la prueba de Kruskal Wallis para probar la hipótesis en a) usando un $\alpha = 0,05$. Concluya.

```

# prueba de Kruskal-Wallis #
kruskal.test(long ~ loc, data = dat_pro1)

```

Resultando:

```

Kruskal-Wallis rank sum test

```

```

data: long by loc
Kruskal-Wallis chi-squared = 16.974, df = 3, p-value = 0.0007155

```

Se concluye que hay diferencias estadísticamente significativas en la longitud de las hojas entre las localidades.

- d) Utilice la prueba de Nemenyi y Dunn para investigar cual es la localidad con mayor longitud usando un $\alpha = 0,05$. Concluya.

```

library(PMCMRplus)
# Nemenyi #
kwAllPairsNemenyiTest(dat\_pro1\$long, dat\_pro1\$loc, dist = "Tukey")
# Dunn #
kwAllPairsDunnTest(dat\_pro1\$long, dat\_pro1\$loc, dist = "Tukey")

```

Resultando:

```
# Nemenyi #
Pairwise comparisons using Tukey-Kramer-Nemenyi all-pairs test with
Tukey-Dist approximation
```

```
data: dat_pro1\long and dat\_pro1\loc
```

```
1      2      3
2 0.6499 -      -
3 0.1729 0.8164 -
4 0.0004 0.0250 0.2117
```

```
# Dunn #
Pairwise comparisons using Dunn's all-pairs test
```

```
data: dat\_pro1\long and dat\_pro1\loc
```

```
1      2      3
2 0.4876 -      -
3 0.1635 0.4876 -
4 0.0004 0.0239 0.1635
```

Con los datos en ambas pruebas se puede concluir que la localidad 1 es la que tiene mayor longitud de hoja y que la localidad 4 es la que menor longitud de hoja.

- e) Utilice el ANOVA de una vía de clasificación para probar la diferencia entre localidades usando un $\alpha = 0,05$. Verifique supuesto de normalidad y homocedasticidad. Concluya. Anexe una gráfica de medias

```
# ANOVA de una Vía
anova1<-aov(long ~ loc, data = dat\_pro1)
summary(anova1)
```

Resultando:

```
Df Sum Sq Mean Sq F value    Pr(>F)
loc          3  19.511    6.504   34.43 4.31e-08 ***
Residuals    20   3.778    0.189
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

De acuerdo al p-value menor que el alpha utilizado, se concluye que existen diferencias significativas.

```
# Supuestos de normalidad
shapiro.test(anova1$residuals)
```

Resultando:

```
# Shapiro-Wilk normality test
data:  anova1$residuals
W = 0.95247, p-value = 0.3063
```

```
# Homocedasticidad
bartlett.test(long ~ loc, data = dat\_pro1)
```

Resultando:

Bartlett test of homogeneity of variances

data: long by loc

Bartlett's K-squared = 6.3705, df = 3, p-value = 0.09491

Con base en los resultados anteriores, los datos cumplieron con el supuesto de normalidad en la prueba de Shapiro Wilk, asimismo con el supuesto de homocedasticidad con la prueba de Bartlet, lo que nos indica que con 5 % de nivel de significancia no existe evidencia de que las varianzas sean estadísticamente diferentes.

Problema 2

Stelzer et al (2012) realizaron ensayos de reacción en cadena de la polimerasa cuantitativa (qPCR) con indicadores fecales para determinar si tres laboratorios estaban proporcionando resultados similares. Se enviaron 21 muestras de fuente fecal a cada uno de los 3 laboratorios. Con las muestras como bloques. Se desea decidir si al menos un laboratorio proporcionó resultados más altos/más bajos que los demás.

Stelzer, E.A., Strickler, K.M., and Schill, W.B., 2012, Interlaboratory comparison of three microbial source tracking quantitative polymerase chain reaction (qPCR) assays from fecal-source and 1 environmental samples: U.S. Geological Survey Scientific Investigations Report 2012–5087, 10 p., <https://doi.org/10.3133/sir20125087>.

Cuadro 2. Contenido de bacterias totales por muestras en tres distintos laboratorios.

Bacterias Totales	Muestra	Laboratorio
44	1	1
42	2	1
180	3	1
200	4	1
190	5	1
200	6	1
190	7	1
48	8	1
54	9	1
33	10	1
57	11	1
55	12	1
44	13	1
53	14	1
60	15	1
127	16	1
3000	17	1
620	18	1
1300	19	1
170	20	1
170	21	1
45	1	2
40	2	2
190	3	2
210	4	2
180	5	2
190	6	2
190	7	2
49	8	2
54	9	2
32	10	2
56	11	2
53	12	2

Bacterias Totales	Muestra	Laboratorio
43	13	2
51	14	2
59	15	2
120	16	2
3000	17	2
620	18	2
1200	19	2
170	20	2
170	21	2
120	1	3
99	2	3
480	3	3
480	4	3
470	5	3
390	6	3
410	7	3
120	8	3
130	9	3
70	10	3
140	11	3
130	12	3
98	13	3
120	14	3
140	15	3
320	16	3
7200	17	3
1500	18	3
2900	19	3
450	20	3
360	21	3

- a) Indique la hipótesis nula y alterna para la prueba de *Friedman* en este problema.

Ho: Los resultados entre los laboratorios son iguales entre sí.

Ha: Los resultados entre los laboratorios son diferentes entre sí.

- b) Obtenga el estadístico de *Friedman* y pruebe Ho usando $\alpha = 0,05$.

```
# Friedman Test #
friedman.test(prob2$bac\_tot, prob2$num,\_lab, prob2$muestra)
```

Resultando:

```
# Friedman rank sum test
```

```
data: prob2$bac\_tot, prob2$num\_lab and prob2$muestra
Friedman chi-squared = 3.1795, df = 2, p-value = 0.204
```

De acuerdo a la prueba anterior, se rechaza la H_0 de que los resultados de los laboratorios son iguales entre si y se concluye que al menos los resultados de un laboratorio es diferente a los demás.

c) Use una prueba de comparación múltiple para determinar que laboratorios difieren de otros. Apoye su decisión usando gráficos

Se realizó una interpretación gráfica boxplot y designando letras para la comparación de medias producto de la prueba post hoc de Nemenyi, que nos permite distinguir la diferencia entre los grupos (laboratorios).

```
# Test post hoc Nemenyi #
nemenyi\_result <- frdAllPairsNemenyiTest(bac\_tot ~ num\_lab | muestra,
data = prob2)
print(nemenyi\_result)

# Extraer las letras de comparación de medias #
nemenyi\_letters <- multcompLetters(nemenyi\_result$p.value)
print(nemenyi\_letters)

# Data frame con las letras para ggplot #
nemenyi\_summary <- data.frame(num\_lab = names(nemenyi\_letters$Letters),
Letters = nemenyi\_letters$Letters)

# Boxplot con letras de comparación de medias #
ggplot(prob2, aes(x = num\_lab, y = bac\_tot, fill = num\_lab)) +
geom\_boxplot() +
geom\_text(data = nemenyi\_summary,
aes(x = num\_lab, y = max(prob2$bac\_tot) + 1, label = Letters),
vjust = 0) +
labs(title = "Comparación de Medias de tres Laboratorios",
x = "Número de Laboratorio",
y = "Bacterias Totales") +
theme\_pubr()
```

Resultando:




Figura 2. Comparación de medias entre laboratorios.

De acuerdo con el gráfico anterior se puede observar que si existe una diferencia estadística significativa y el laboratorio 3 es el que tiene una media superior a los otros dos laboratorios. Afirmando el resultado en la prueba de *Friedman*.

Problema 3

Se diseñó una serie de experimentos para comprobar la hipótesis de que la siembra masiva de yoduro de plata puede, en determinadas condiciones, provocar un aumento de las precipitaciones.

Los datos de estos experimentos se publicaron en el artículo "*A Bayesian Analysis of a Multiplicative Treatment Effect in Weather Modification*" [*Technometrics* (1975) 17:161-166]. Aquí se informa del volumen de lluvia que cae de la nube tras la siembra con yoduro de plata.

Cuadro 3. Tabla de datos de siembra de nubes.

Rainfall (acre-feet)Unseeded Clouds (RCU)							
129.6	31.4	2745.6	489.1	430	302.8	119	4.1
92.4	17.5	200.7	274.7	274.7	7.7	1656	978
198.6	703.4	1697.8	334.1	118.3	255	115.3	242.5
32.7	40.6						
Rainfall (acre-feet)Seeded Clouds (RSC)							
26.1	26.3	87	95	372.4	0	17.3	24.4
11.5	321.2	68.5	81.2	47.3	28.6	830.1	345.5
1202.6	36.6	4.9	4.9	41.1	29	163	244.3
147.8	21.7						

- a) Use la prueba de Ansari-Bradley para probar si la variabilidad en ambos tratamientos es igual, establezca su juego de hipótesis, gráficos y conclusiones con $\alpha = 0,05$.

Ho: La variabilidad de lluvias en ambos casos es igual.

Ha: La variabilidad de lluvias en ambos casos no es igual.

Como primer impresión se realiza una grafica boxplot (Figura 3). Código siguiente:

```
# Gráfica boxplot #
ggboxplot(dat3, x = "trat", y = "rain",
  xlab= "Tratamiento",ylab="Lluvia (mm)",
  color = "trat", palette = "jco",
  add = "jitter", facet.by = NULL,
  ggtheme = theme_pubr())
```




Figura 3. Precipitación (mm) por tratamiento. RUC: Rainfall Unseeded Clouds; RSC: Rainfall Seeded Clouds

En la gráfica anterior se puede observar que existe una diferencia mínima visualmente en la distribución y media de los datos de cada uno de los tratamientos. Sin embargo, para poder concluir con certeza una diferencia estadística entre ambos casos se realiza a continuación la prueba de *Ansari-Bradley* y *Kolmogorov-Smirnov*.

Prueba de Ansari-Bradley

```
ansari.test(rain~trat, dat3, var.equal=TRUE, alternative="two.sided",
alpha=0.05)
```

Resultando:

```
Ansari-Bradley test
data: rain by trat
AB = 344, p-value = 0.7976
alternative hypothesis: true ratio of scales is not equal to 1
```

De acuerdo a la prueba anterior y con un $\alpha = 0,05$, se puede concluir que no existe diferencia estadísticamente significativas en la varianza de las lluvias entre ambos tratamientos.

- b) Use la prueba de Kolmogorov-Smirnov para probar si las distribuciones de precipitación son iguales en ambos tratamientos, use $\alpha = 0,05$.

Prueba de Kolmogorov-Smirnov

```
ks.test(rain~trat, dat3, alternative="two.sided")
```

Resultando:

```
Exact two-sample Kolmogorov-Smirnov test

data: rain by trat
D = 0.42308, p-value = 0.01774
alternative hypothesis: two-sided
```

De la misma manera que con la prueba de *Ansari-Bradley*, con un $\alpha = 0,05$, se puede concluir que no existe diferencia estadísticamente significativa en la distribución de las lluvias entre ambos tratamientos.

Problema 4

Nappi (E12) investigó los cambios que se producen en los hemocitos de larvas de *Drosophila algonquin* durante la parasitación por el himenóptero parásito (parasitoide) *Pseudocoila bochei*. Diez y siete horas después de la parasitación de larvas de *Drosophila algonquin*, se efectuaron recuentos diferenciales (%) de plasmocitos en tres grupos: larvas hospedadoras en las que la reacción fue satisfactoria (S), larvas en las que la reacción no fue satisfactoria (U) y larvas en las que no hubo reacción visible del hospedador (N). Los resultados se muestran en la Tabla 6.16. Se desea comprobar la hipótesis nula de que no hay diferencia entre los tres grupos frente a la alternativa de que los recuentos diferenciales de plasmocitos (%) disminuyen en los tres grupos del grupo N al grupo S.

Cuadro 4. Differential plasmocyte counts, percent from larvae of *Drosophila algonquin* 27 hours after parasitization by *Pseudecoila bochei* (host age 91 hours when parasitized).

Successful host reactions (S)	Unsuccessful host reactions (U)	No visible host reactions (N)
54.0	79.8	98.6
67.0	82.0	99.5
47.2	88.8	95.8
71.1	79.6	93.3
62.7	85.7	98.9
44.8	81.7	91.1
67.4	88.5	94.5
80.2		

- a) Use la prueba de Jonckheere-Terpstra, escriba el juego de hipótesis y concluya $\alpha = 0,05$.

Ho: No hay diferencias entre los tres grupos.

Ha: Los recuentos diferenciales de plasmocitos (%) disminuyen en los tres grupos, del grupo N al grupo S.

Prueba de Jonckheere-Terpstra:

```
# Prueba de Jonckheere-Terpstra #
jonckheereTest(prob4$counts, prob4$groups, alternative = "greater")
```

Resultado:

Jonckheere-Terpstra test

```
data: prob4$counts and prob4$groups
z = 4.7259, p-value = 1.146e-06
alternative hypothesis: greater
sample estimates:
JT
159
```

De acuerdo a la prueba anterior se rechaza la hipótesis nula, por lo que se puede decir que existe una diferencia entre los grupos ya que el valor de p-value, es menor al $\alpha = 0,05$.

Ademas de observar que una tendencia creciente en la variable counts del grupo S al N (Figura 4).

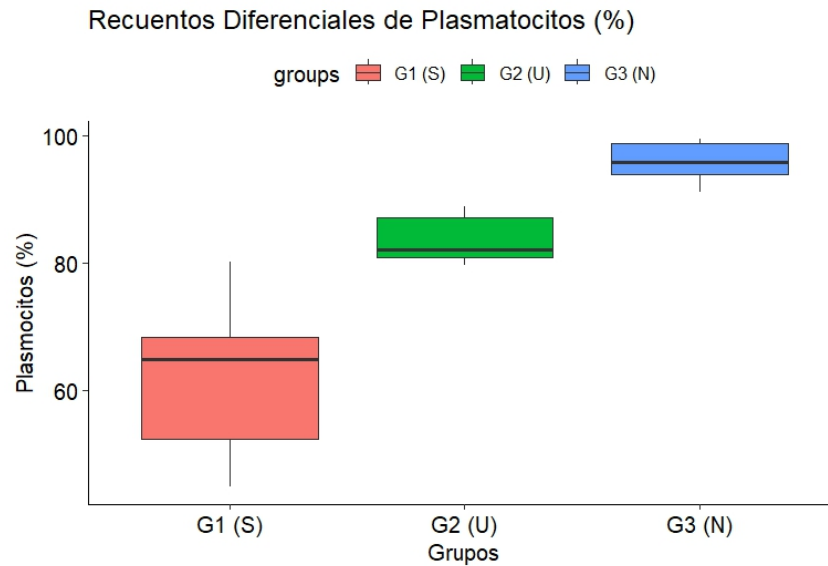


Figura 4. Porcentaje de recuentos de plasmotocitos para los tres grupos.

Problema 5

Del artículo:

Edward Durner, 2019. Effective Analysis of Interactive Effects with Non Normal Data Using the Aligned Rank Transform, ARTool and SAS University Edition, *Horticulturae* 2019, 5, 57; doi:10.3390/horticulturae5030057.

Escribir un reporte: con tablas gráficos interpretación y conclusiones.

Consideraciones: consider an experiment where six rates of three nitrogen sources were evaluated for strawberry yield (g·plant⁻¹). The experimental design was a split plot with nitrogen source as the main plot and nitrogen rate as the sub-plot. There were five replicates of the main plot and the main plots were set in a randomized complete block design.

- Analice los datos para un modelo de parcelas divididas en forma paramétrica.
- Utilizando el modelo de parcelas divididas (paramétrico).

```
# Parcelas divididas (paramétrico) #
# Análisis de varianza #
anova_par_div<-aov(Yield ~ blk+ Nitrogen*Rate +
Error(blk:Nitrogen), data = datos3)
summary(anova_par_div)
```

Resultando:

```
Error: blk:Nitrogen
Df Sum Sq Mean Sq
blk      1      551      551
Nitrogen  2 116448  58224
```

```
Error: Within
Df Sum Sq Mean Sq F value    Pr(>F)
Nitrogen      2   26688   13344  7.640 0.000913 ***
Rate          1    2321    2321  1.329 0.252431
Nitrogen:Rate  2   14077    7039  4.030 0.021456 *
Residuals     81 141475    1747
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

De acuerdo a la prueba anterior, se puede concluir que no existió algún efecto de los tratamientos y su combinación, dado que todos los pvalue se encontraron por encima del alfa ($\alpha = 0,05$).

- Pruebe los efectos de tratamientos y la interacción tratamiento vs tiempo, use $\alpha = 0,5$. Verifique supuestos.

Comprobación de supuestos

Independencia

De una manera visual, podemos comprobar la normalidad de los datos mediante gráficos qqline. Estos gráficos muestran que en las 3 Variedades se pudiera suponer normalidad; sin embargo, es necesario establecer el juego de hipótesis.

```
par(mfrow = c(2,2))
qqnorm(datos3[datos3$Rate=="1","Yield" ], main="Var1")
qqline(datos3[datos3$Rate=="1","Yield" ])
qqnorm(datos3[datos3$Rate=="2","Yield" ], main="Var2")
qqline(datos3[datos3$Rate=="2","Yield" ])
qqnorm(datos3[datos3$Rate=="3","Yield" ], main="Var3")
qqline(datos3[datos3$Rate=="3","Yield" ])
qqnorm(datos3[datos3$Rate=="4","Yield" ], main="Var4")
qqline(datos3[datos3$Rate=="4","Yield" ])
qqnorm(datos3[datos3$Rate=="5","Yield" ], main="Var5")
qqline(datos3[datos3$Rate=="5","Yield" ])
qqnorm(datos3[datos3$Rate=="6","Yield" ], main="Var6")
qqline(datos3[datos3$Rate=="6","Yield" ])
```

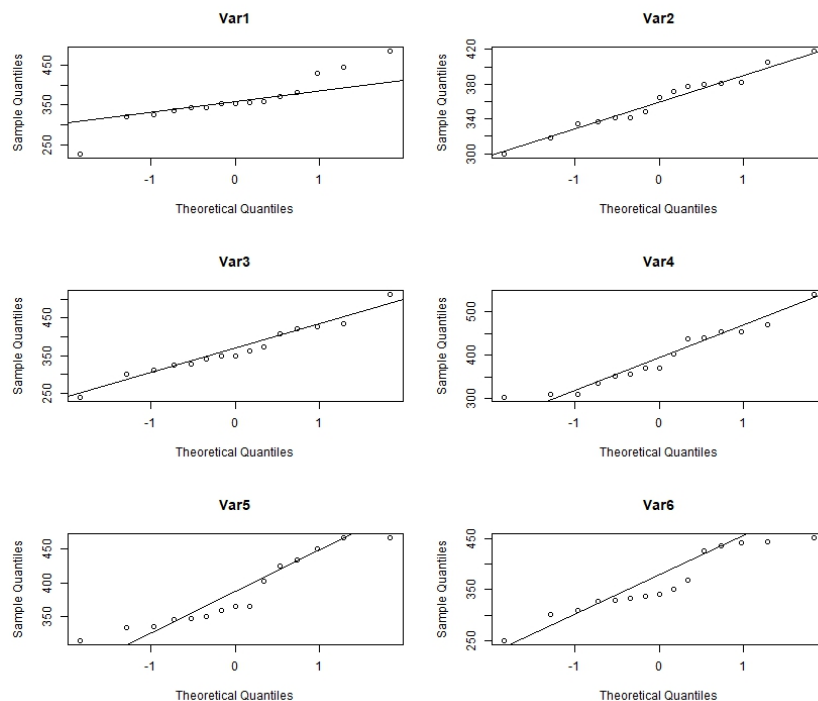


Figura 5. Gráficos qqline, para verificación de independencia de los datos.

Test de hipótesis

Dado que los grupos tienen más de 50 observaciones se emplea el test de Kolmogorov-Smirnov con la corrección de Lilliefors.

```
by(data = datos3, INDICES = datos3$Rate,
FUN = function(x){ lillie.test(x$Yield)})
```

```
atos3$Rate: 1
```

```
Lilliefors (Kolmogorov-Smirnov) normality test
```

```
data: x$Yield
```

```
D = 0.19346, p-value = 0.1368
```

```
-----  
datos3$Rate: 2
```

```
Lilliefors (Kolmogorov-Smirnov) normality test
```

```
data: x$Yield
```

```
D = 0.1143, p-value = 0.8624
```

```
-----  
datos3$Rate: 3
```

```
Lilliefors (Kolmogorov-Smirnov) normality test
```

```
data: x$Yield
```

```
D = 0.13076, p-value = 0.7005
```

```
-----  
datos3$Rate: 4
```

```
Lilliefors (Kolmogorov-Smirnov) normality test
```

```
data: x$Yield
```

```
D = 0.15816, p-value = 0.3978
```

```
-----  
datos3$Rate: 5
```

```
Lilliefors (Kolmogorov-Smirnov) normality test
```

```
data: x$Yield
```

```
D = 0.24007, p-value = 0.02
```

```
-----  
datos3$Rate: 6
```

```
Lilliefors (Kolmogorov-Smirnov) normality test
```

```
data: x$Yield
```

```
D = 0.18257, p-value = 0.196
```

De esta manera se puede observar que todas las variedades cumplen con el supuesto. Sin embargo para Rate 2, esta casi en el límite para aceptar que se distribuye de forma

normal.

Homocedasticidad

Tomando en cuenta que hay un grupo (Rate 2) que se encuentra en el límite para aceptar que se distribuye de forma normal el test de Fisher y el de Bartlett no son recomendables. En su lugar es mejor emplea un test basado en la mediana test de Levene o test de Fligner-Killeen.

```
fligner.test(Yield ~ Rate, data = datos3)
```

Resultando:

Fligner-Killeen test of homogeneity of variances

data: Yield by Rate

Fligner-Killeen:med chi-squared = 4.6617, df = 5, p-value = 0.4585

Con una confiabilidad de 95% y de acuerdo con el test de Fligner-Killeen con un p-value de 0.4585 se acepta la hipótesis de homocedasticidad;es decir, las varianzas son iguales.

- d) Utilice el método de Tukey para investigar cual es el mejor tratamiento.

```
# Prueba de Tukey #
```

```
anova_simplified <- aov(Yield ~ blk + Nitrogen * Rate, data = datos3)
```

```
tukey_result <- TukeyHSD(anova_simplified)
```

```
tukey_result
```

```
plot(tukey_result)
```




Figura 6. Grafico de la comparación de medias Tukey $\alpha = 0,05$).

En la Figura anterior, se puede observar que el efecto de los niveles de nitrógeno tienen medias muy parecidas entre si, dado que se encuentran cerca de la media.

e) Realizar la gráfica de interacción nit*rate e interpretar.

```
# Grafico de interacción #
interaction.plot(datos3$Nitrogen, datos3$Rate, datos3$Yiel)
interaction.plot(datos3$Nitrogen, datos3$Rate, datos3$Yield,
type = "l",
ylab= "Yield",
xlab = "Nitrogen",
col = c("blue4", "red4", "green", "orange"),
lty = 1,
lwd = 2,
trace.label = "Rate",
xpd = FALSE)
```

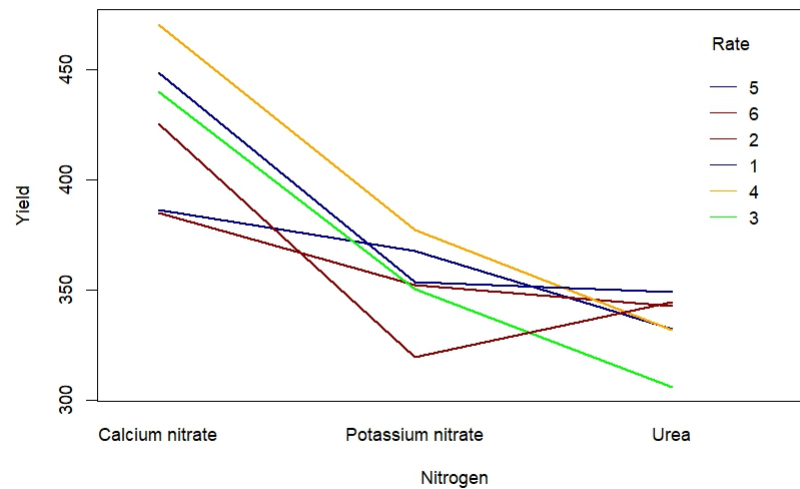


Figura 7. Gráfico de interacción Rate*Nitrogen.

De acuerdo a la gráfica anterior se puede observar una interacción entre todos los niveles, siendo mas evidente para el 1.

- f) Realice el análisis no paramétrico utilizando rangos alineados con ARtool.

```
# Parcelas divididas (no parametrico) con ArTool #
# Análisis de varianza #
anova_rangos<- art(Yield ~ Nitrogen*Rate+ (1|blk),data=datos3)
anova(anova_rangos)
# Prueba de Tukey #
media<-artlm(anova_rangos,"Nitrogen:Rate")
marginal<-emmeans(media, ~Nitrogen*Rate)
marginal
pares<-pairs(marginal,adjust = "tukey")
pares
plot(marginal)
```

Resultando:

```
> anova(anova_rangos)
Analysis of Variance of Aligned Rank Transformed Data
```

```
Table Type: Analysis of Deviance Table (Type III Wald F tests with Kenward-Roger
Model: Mixed Effects (lmer)
Response: art(Yield)
```

	F	Df	Df.res	Pr(>F)
1 Nitrogen	46.7553	2	68	1.6845e-13 ***
2 Rate	3.5499	5	68	0.0065398 **
3 Nitrogen:Rate	2.8759	10	68	0.0047463 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

El análisis de la varianza evidencia que no existe diferencia estadísticamente significativa entre los factores y sus interacciones, ya que los pvalue son mayores al alfa utilizado ($\alpha = 0,05$).

Al haberse rechazado la hipótesis y no existir diferencia estadística significativa, no se tendría caso realizar una prueba de comparación de medias sin embargo; con fines didácticos se realiza la siguiente prueba.

Prueba de Tukey

```
media<-artlm(anova_rangos,"Nitrogen:Rate")
marginal<-emmeans(media, ~Nitrogen*Rate)
marginal
pares<-pairs(marginal,adjust = "tukey")
pares
plot(marginal)+theme_pubr()
```

Resultando:

```
> marginal
```

Nitrogen	Rate	emmean	SE	df	lower.CL	upper.CL
Calcium nitrate	1	22.2	11	72	0.36	44.0
Potassium nitrate	1	59.3	11	72	37.46	81.1
Urea	1	53.1	11	72	31.26	74.9
Calcium nitrate	2	17.7	11	72	-4.14	39.5
Potassium nitrate	2	59.5	11	72	37.66	81.3
Urea	2	56.5	11	72	34.66	78.3
Calcium nitrate	3	58.0	11	72	36.16	79.8
Potassium nitrate	3	50.8	11	72	28.96	72.6
Urea	3	33.8	11	72	11.96	55.6
Calcium nitrate	4	60.6	11	72	38.76	82.4
Potassium nitrate	4	42.2	11	72	20.36	64.0
Urea	4	26.0	11	72	4.16	47.8
Calcium nitrate	5	58.0	11	72	36.16	79.8
Potassium nitrate	5	34.8	11	72	12.96	56.6
Urea	5	45.5	11	72	23.66	67.3
Calcium nitrate	6	58.4	11	72	36.56	80.2
Potassium nitrate	6	31.0	11	72	9.16	52.8
Urea	6	51.6	11	72	29.76	73.4

Degrees-of-freedom method: kenward-roger

Confidence level used: 0.95

```
> pares
```

contrast	estimate	SE	df	t.ratio	p.value
CalciumN Rate1 - PotassiumN Rate1	-37.1	15.5	68	-2.395	0.6138
CalciumN Rate1 - Urea Rate1	-30.9	15.5	68	-1.995	0.8613
CalciumN Rate1 - CalciumN Rate2	4.5	15.5	68	0.290	1.0000
CalciumN Rate1 - PotassiumN Rate2	-37.3	15.5	68	-2.408	0.6046
CalciumN Rate1 - Urea Rate2	-34.3	15.5	68	-2.214	0.7375
CalciumN Rate1 - CalciumN Rate3	-35.8	15.5	68	-2.311	0.6727
CalciumN Rate1 - PotassiumN Rate3	-28.6	15.5	68	-1.846	0.9210

CalciumN	Rate1 - Urea	Rate3	-11.6	15.5	68	-0.749	1.0000
CalciumN	Rate1 - CalciumN	Rate4	-38.4	15.5	68	-2.479	0.5537
CalciumN	Rate1 - PotassiumN	Rate4	-20.0	15.5	68	-1.291	0.9976
CalciumN	Rate1 - Urea	Rate4	-3.8	15.5	68	-0.245	1.0000
CalciumN	Rate1 - CalciumN	Rate5	-35.8	15.5	68	-2.311	0.6727
CalciumN	Rate1 - PotassiumN	Rate5	-12.6	15.5	68	-0.813	1.0000
CalciumN	Rate1 - Urea	Rate5	-23.3	15.5	68	-1.504	0.9875
CalciumN	Rate1 - CalciumN	Rate6	-36.2	15.5	68	-2.337	0.6548
CalciumN	Rate1 - PotassiumN	Rate6	-8.8	15.5	68	-0.568	1.0000
CalciumN	Rate1 - Urea	Rate6	-29.4	15.5	68	-1.898	0.9026
PotassiumN	Rate1 - Urea	Rate1	6.2	15.5	68	0.400	1.0000
PotassiumN	Rate1 - CalciumN	Rate2	41.6	15.5	68	2.685	0.4099
PotassiumN	Rate1 - PotassiumN	Rate2	-0.2	15.5	68	-0.013	1.0000
PotassiumN	Rate1 - Urea	Rate2	2.8	15.5	68	0.181	1.0000
PotassiumN	Rate1 - CalciumN	Rate3	1.3	15.5	68	0.084	1.0000
PotassiumN	Rate1 - PotassiumN	Rate3	8.5	15.5	68	0.549	1.0000
PotassiumN	Rate1 - Urea	Rate3	25.5	15.5	68	1.646	0.9701
PotassiumN	Rate1 - CalciumN	Rate4	-1.3	15.5	68	-0.084	1.0000
PotassiumN	Rate1 - PotassiumN	Rate4	17.1	15.5	68	1.104	0.9997
PotassiumN	Rate1 - Urea	Rate4	33.3	15.5	68	2.150	0.7777
PotassiumN	Rate1 - CalciumN	Rate5	1.3	15.5	68	0.084	1.0000
PotassiumN	Rate1 - PotassiumN	Rate5	24.5	15.5	68	1.582	0.9794
PotassiumN	Rate1 - Urea	Rate5	13.8	15.5	68	0.891	1.0000
PotassiumN	Rate1 - CalciumN	Rate6	0.9	15.5	68	0.058	1.0000
PotassiumN	Rate1 - PotassiumN	Rate6	28.3	15.5	68	1.827	0.9273
PotassiumN	Rate1 - Urea	Rate6	7.7	15.5	68	0.497	1.0000
Urea	Rate1 - CalciumN	Rate2	35.4	15.5	68	2.285	0.6904
Urea	Rate1 - PotassiumN	Rate2	-6.4	15.5	68	-0.413	1.0000
Urea	Rate1 - Urea	Rate2	-3.4	15.5	68	-0.219	1.0000
Urea	Rate1 - CalciumN	Rate3	-4.9	15.5	68	-0.316	1.0000
Urea	Rate1 - PotassiumN	Rate3	2.3	15.5	68	0.148	1.0000
Urea	Rate1 - Urea	Rate3	19.3	15.5	68	1.246	0.9984
Urea	Rate1 - CalciumN	Rate4	-7.5	15.5	68	-0.484	1.0000
Urea	Rate1 - PotassiumN	Rate4	10.9	15.5	68	0.704	1.0000
Urea	Rate1 - Urea	Rate4	27.1	15.5	68	1.749	0.9489
Urea	Rate1 - CalciumN	Rate5	-4.9	15.5	68	-0.316	1.0000
Urea	Rate1 - PotassiumN	Rate5	18.3	15.5	68	1.181	0.9992
Urea	Rate1 - Urea	Rate5	7.6	15.5	68	0.491	1.0000
Urea	Rate1 - CalciumN	Rate6	-5.3	15.5	68	-0.342	1.0000
Urea	Rate1 - PotassiumN	Rate6	22.1	15.5	68	1.427	0.9928
Urea	Rate1 - Urea	Rate6	1.5	15.5	68	0.097	1.0000
CalciumN	Rate2 - PotassiumN	Rate2	-41.8	15.5	68	-2.698	0.4014
CalciumN	Rate2 - Urea	Rate2	-38.8	15.5	68	-2.505	0.5353
CalciumN	Rate2 - CalciumN	Rate3	-40.3	15.5	68	-2.601	0.4669
CalciumN	Rate2 - PotassiumN	Rate3	-33.1	15.5	68	-2.137	0.7854
CalciumN	Rate2 - Urea	Rate3	-16.1	15.5	68	-1.039	0.9998
CalciumN	Rate2 - CalciumN	Rate4	-42.9	15.5	68	-2.769	0.3561
CalciumN	Rate2 - PotassiumN	Rate4	-24.5	15.5	68	-1.582	0.9794

CalciumN	Rate2 - Urea	Rate4	-8.3	15.5	68	-0.536	1.0000
CalciumN	Rate2 - CalciumN	Rate5	-40.3	15.5	68	-2.601	0.4669
CalciumN	Rate2 - PotassiumN	Rate5	-17.1	15.5	68	-1.104	0.9997
CalciumN	Rate2 - Urea	Rate5	-27.8	15.5	68	-1.795	0.9369
CalciumN	Rate2 - CalciumN	Rate6	-40.7	15.5	68	-2.627	0.4491
CalciumN	Rate2 - PotassiumN	Rate6	-13.3	15.5	68	-0.859	1.0000
CalciumN	Rate2 - Urea	Rate6	-33.9	15.5	68	-2.188	0.7539
PotassiumN	Rate2 - Urea	Rate2	3.0	15.5	68	0.194	1.0000
PotassiumN	Rate2 - CalciumN	Rate3	1.5	15.5	68	0.097	1.0000
PotassiumN	Rate2 - PotassiumN	Rate3	8.7	15.5	68	0.562	1.0000
PotassiumN	Rate2 - Urea	Rate3	25.7	15.5	68	1.659	0.9679
PotassiumN	Rate2 - CalciumN	Rate4	-1.1	15.5	68	-0.071	1.0000
PotassiumN	Rate2 - PotassiumN	Rate4	17.3	15.5	68	1.117	0.9996
PotassiumN	Rate2 - Urea	Rate4	33.5	15.5	68	2.162	0.7699
PotassiumN	Rate2 - CalciumN	Rate5	1.5	15.5	68	0.097	1.0000
PotassiumN	Rate2 - PotassiumN	Rate5	24.7	15.5	68	1.594	0.9778
PotassiumN	Rate2 - Urea	Rate5	14.0	15.5	68	0.904	1.0000
PotassiumN	Rate2 - CalciumN	Rate6	1.1	15.5	68	0.071	1.0000
PotassiumN	Rate2 - PotassiumN	Rate6	28.5	15.5	68	1.840	0.9231
PotassiumN	Rate2 - Urea	Rate6	7.9	15.5	68	0.510	1.0000
Urea	Rate2 - CalciumN	Rate3	-1.5	15.5	68	-0.097	1.0000
Urea	Rate2 - PotassiumN	Rate3	5.7	15.5	68	0.368	1.0000
Urea	Rate2 - Urea	Rate3	22.7	15.5	68	1.465	0.9904
Urea	Rate2 - CalciumN	Rate4	-4.1	15.5	68	-0.265	1.0000
Urea	Rate2 - PotassiumN	Rate4	14.3	15.5	68	0.923	1.0000
Urea	Rate2 - Urea	Rate4	30.5	15.5	68	1.969	0.8732
Urea	Rate2 - CalciumN	Rate5	-1.5	15.5	68	-0.097	1.0000
Urea	Rate2 - PotassiumN	Rate5	21.7	15.5	68	1.401	0.9941
Urea	Rate2 - Urea	Rate5	11.0	15.5	68	0.710	1.0000
Urea	Rate2 - CalciumN	Rate6	-1.9	15.5	68	-0.123	1.0000
Urea	Rate2 - PotassiumN	Rate6	25.5	15.5	68	1.646	0.9701
Urea	Rate2 - Urea	Rate6	4.9	15.5	68	0.316	1.0000
CalciumN	Rate3 - PotassiumN	Rate3	7.2	15.5	68	0.465	1.0000
CalciumN	Rate3 - Urea	Rate3	24.2	15.5	68	1.562	0.9817
CalciumN	Rate3 - CalciumN	Rate4	-2.6	15.5	68	-0.168	1.0000
CalciumN	Rate3 - PotassiumN	Rate4	15.8	15.5	68	1.020	0.9999
CalciumN	Rate3 - Urea	Rate4	32.0	15.5	68	2.066	0.8255
CalciumN	Rate3 - CalciumN	Rate5	0.0	15.5	68	0.000	1.0000
CalciumN	Rate3 - PotassiumN	Rate5	23.2	15.5	68	1.498	0.9880
CalciumN	Rate3 - Urea	Rate5	12.5	15.5	68	0.807	1.0000
CalciumN	Rate3 - CalciumN	Rate6	-0.4	15.5	68	-0.026	1.0000
CalciumN	Rate3 - PotassiumN	Rate6	27.0	15.5	68	1.743	0.9505
CalciumN	Rate3 - Urea	Rate6	6.4	15.5	68	0.413	1.0000
PotassiumN	Rate3 - Urea	Rate3	17.0	15.5	68	1.097	0.9997
PotassiumN	Rate3 - CalciumN	Rate4	-9.8	15.5	68	-0.633	1.0000
PotassiumN	Rate3 - PotassiumN	Rate4	8.6	15.5	68	0.555	1.0000
PotassiumN	Rate3 - Urea	Rate4	24.8	15.5	68	1.601	0.9769
PotassiumN	Rate3 - CalciumN	Rate5	-7.2	15.5	68	-0.465	1.0000

PotassiumN	Rate3	-	PotassiumN	Rate5	16.0	15.5	68	1.033	0.9999
PotassiumN	Rate3	-	Urea	Rate5	5.3	15.5	68	0.342	1.0000
PotassiumN	Rate3	-	CalciumN	Rate6	-7.6	15.5	68	-0.491	1.0000
PotassiumN	Rate3	-	PotassiumN	Rate6	19.8	15.5	68	1.278	0.9979
PotassiumN	Rate3	-	Urea	Rate6	-0.8	15.5	68	-0.052	1.0000
Urea	Rate3	-	CalciumN	Rate4	-26.8	15.5	68	-1.730	0.9535
Urea	Rate3	-	PotassiumN	Rate4	-8.4	15.5	68	-0.542	1.0000
Urea	Rate3	-	Urea	Rate4	7.8	15.5	68	0.503	1.0000
Urea	Rate3	-	CalciumN	Rate5	-24.2	15.5	68	-1.562	0.9817
Urea	Rate3	-	PotassiumN	Rate5	-1.0	15.5	68	-0.065	1.0000
Urea	Rate3	-	Urea	Rate5	-11.7	15.5	68	-0.755	1.0000
Urea	Rate3	-	CalciumN	Rate6	-24.6	15.5	68	-1.588	0.9786
Urea	Rate3	-	PotassiumN	Rate6	2.8	15.5	68	0.181	1.0000
Urea	Rate3	-	Urea	Rate6	-17.8	15.5	68	-1.149	0.9994
CalciumN	Rate4	-	PotassiumN	Rate4	18.4	15.5	68	1.188	0.9991
CalciumN	Rate4	-	Urea	Rate4	34.6	15.5	68	2.233	0.7249
CalciumN	Rate4	-	CalciumN	Rate5	2.6	15.5	68	0.168	1.0000
CalciumN	Rate4	-	PotassiumN	Rate5	25.8	15.5	68	1.665	0.9667
CalciumN	Rate4	-	Urea	Rate5	15.1	15.5	68	0.975	0.9999
CalciumN	Rate4	-	CalciumN	Rate6	2.2	15.5	68	0.142	1.0000
CalciumN	Rate4	-	PotassiumN	Rate6	29.6	15.5	68	1.911	0.8976
CalciumN	Rate4	-	Urea	Rate6	9.0	15.5	68	0.581	1.0000
PotassiumN	Rate4	-	Urea	Rate4	16.2	15.5	68	1.046	0.9998
PotassiumN	Rate4	-	CalciumN	Rate5	-15.8	15.5	68	-1.020	0.9999
PotassiumN	Rate4	-	PotassiumN	Rate5	7.4	15.5	68	0.478	1.0000
PotassiumN	Rate4	-	Urea	Rate5	-3.3	15.5	68	-0.213	1.0000
PotassiumN	Rate4	-	CalciumN	Rate6	-16.2	15.5	68	-1.046	0.9998
PotassiumN	Rate4	-	PotassiumN	Rate6	11.2	15.5	68	0.723	1.0000
PotassiumN	Rate4	-	Urea	Rate6	-9.4	15.5	68	-0.607	1.0000
Urea	Rate4	-	CalciumN	Rate5	-32.0	15.5	68	-2.066	0.8255
Urea	Rate4	-	PotassiumN	Rate5	-8.8	15.5	68	-0.568	1.0000
Urea	Rate4	-	Urea	Rate5	-19.5	15.5	68	-1.259	0.9982
Urea	Rate4	-	CalciumN	Rate6	-32.4	15.5	68	-2.091	0.8114
Urea	Rate4	-	PotassiumN	Rate6	-5.0	15.5	68	-0.323	1.0000
Urea	Rate4	-	Urea	Rate6	-25.6	15.5	68	-1.653	0.9690
CalciumN	Rate5	-	PotassiumN	Rate5	23.2	15.5	68	1.498	0.9880
CalciumN	Rate5	-	Urea	Rate5	12.5	15.5	68	0.807	1.0000
CalciumN	Rate5	-	CalciumN	Rate6	-0.4	15.5	68	-0.026	1.0000
CalciumN	Rate5	-	PotassiumN	Rate6	27.0	15.5	68	1.743	0.9505
CalciumN	Rate5	-	Urea	Rate6	6.4	15.5	68	0.413	1.0000
PotassiumN	Rate5	-	Urea	Rate5	-10.7	15.5	68	-0.691	1.0000
PotassiumN	Rate5	-	CalciumN	Rate6	-23.6	15.5	68	-1.523	0.9857
PotassiumN	Rate5	-	PotassiumN	Rate6	3.8	15.5	68	0.245	1.0000
PotassiumN	Rate5	-	Urea	Rate6	-16.8	15.5	68	-1.084	0.9997
Urea	Rate5	-	CalciumN	Rate6	-12.9	15.5	68	-0.833	1.0000
Urea	Rate5	-	PotassiumN	Rate6	14.5	15.5	68	0.936	1.0000
Urea	Rate5	-	Urea	Rate6	-6.1	15.5	68	-0.394	1.0000
CalciumN	Rate6	-	PotassiumN	Rate6	27.4	15.5	68	1.769	0.9440

CalciumN	Rate6 - Urea Rate6	6.8	15.5	68	0.439	1.0000
PotassiumN	Rate6 - Urea Rate6	-20.6	15.5	68	-1.330	0.9967

Degrees-of-freedom method: kenward-roger

P value adjustment: tukey method for comparing a family of 18 estimates

La prueba anterior muestra que no existe diferencia entre las entre las interacciones, ya que todos los p-value son 1 o cercanos a 1




Figura 8. Comparación de medias

En el gráfico anterior se muestra la comparación de medias entre los niveles del factor Nitrógeno, evidenciando que no existe una diferencia estadística significativa

Problema 6

Los machos de la magnífica fragata (*Fregata magnificens*) tienen una gran bolsa roja en la garganta. Muestran visualmente esta bolsa y la usan para emitir un sonido de tambor cuando buscan pareja. Madsen et al. (2004) querían saber si las hembras, que presumiblemente eligen pareja en función del tamaño de su bolsa, podían utilizar el tono del sonido del tambor como indicador del tamaño de su bolsa. Los autores estimaron el volumen de la bolsa y la frecuencia fundamental del sonido del tambor en 18 machos.

Cuadro 5. Volumen de bolsa y Frecuencia fundamental emitida.

Volume (cm^3)	Frecuency (Hz)
1760	529
2040	566
2440	473
2550	461
2730	465
2740	532
3010	484
3080	527
3370	488
3740	485
4910	478
5090	434
5090	468
5380	449
5850	425
6730	389
6990	421
7960	416

a) Realice una gráfica X vs Y.

```
dat<-read.csv("prob6.csv", header=T)
Frecuencia<-dat$freq
Volumen<-dat$volume
attach(dat)
str(dat)
cor(Volumen,Frecuencia)
plot(Volumen,Frecuencia)
```




Figura 9. Gráfica x & y de la Frecuencia emitida y el Volumen.

- b) Obtenga el coeficiente de correlación de Spearman, Kendall y de Pearson. Interprete.

```
# Paramétrica #
cor(Volumen, Frecuencia)

# No paramétrica #
# Spearman Test #
cor.test(Volumen, Frecuencia, method = "spearman")
# Kendall Test #
cor.test(Volumen, Frecuencia, method = "kendall")
```

Resultando:

Pearson's product-moment correlation

```
data: Volumen and Frecuencia
t = -5.7375, df = 16, p-value = 3.056e-05
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
-0.9307345 -0.5728357
sample estimates:
cor
-0.8203196
```

Spearman's rank correlation rho

```
data: Volumen and Frecuencia
S = 1708.4, p-value = 0.0002302
alternative hypothesis: true rho is not equal to 0
```

```
sample estimates:
```

```
rho
```

```
-0.7630357
```

```
Kendall's rank correlation tau
```

```
data: Volumen and Frecuencia
```

```
z = -3.5631, p-value = 0.0003666
```

```
alternative hypothesis: true tau is not equal to 0
```

```
sample estimates:
```

```
tau
```

```
-0.6163968
```

En todos los tests, se pudo evidenciar una correlación entre ambas variables (Volumen y Frecuencia), ya que los coeficientes son mayores a 0.5 y el p- value en todos los casos fue menor al alfa ($\alpha = 0,5$). De igual manera, esta correlación en todos los casos siempre fue negativa. Por lo que se concluye que existe una correlación negativa entre ambas variables.

Problema 7

Del trabajo:

KOKLU, M. and OZKAN, I.A., (2020), Multiclass Classification of Dry Beans Using Computer Vision and Machine Learning Techniques. *Computers and Electronics in Agriculture*, 174, 105507. <https://doi.org/10.1016/j.compag.2020.105507>.

En esta investigación se utilizaron siete diferentes variedades de frijoles secos, teniendo en cuenta las características como forma, aspecto, tipo y estructura según la situación del mercado. Se desarrolló un sistema de visión por computadora para distinguir siete variedades diferentes registradas de frijol seco con características similares para obtener una clasificación uniforme de semillas. Para el modelo de clasificación se tomaron imágenes de 13,611 granos de siete variedades de granos de frijol secos diferentes registrados con una cámara de alta resolución. Las imágenes de frijoles obtenidas por el sistema de visión por computadora se sometieron a etapas de segmentación y extracción de características, y un total de 16 características; De los granos se obtuvieron 12 dimensiones y 4 formas.

- a) Realice un análisis de correlación para investigar la relación entre atributos de las semillas de frijol utilizando los coeficientes de Pearson, Spearman y Kendall, interprete sus resultados. Los atributos presentan normalidad.

Como primer paso para abordar el problema se necesita corroborar la normalidad de los datos y conocer su distribución. Dado que el número de observaciones supera 10,000 (y para la prueba se sugiere se maneje en un rango de 3 a 5000 observaciones) se utilizó el paquete *skim* para desglosar los atributos y de una manera visual poder identificar con un histograma dicha normalidad. Este es un método rudimentario en la exploración, sin embargo para apoyar estadísticamente los resultados se debe correr la prueba de Shapiro Wilk.

```
# Datos #
dat7<-read.csv("prob7.csv",header = T)
View(dat7)
# Librerías #
library(ggplot2)
library(skimr)
# Explorar los datos #
glimpse(dat7)
dat7<- as.data.frame(lapply(dat7[, -17], as.numeric))
# Comprobar normalidad de los datos #
skim(dat7[, -17])
```

Variable type: numeric						
skim_variable	n_missing	complete_rate	mean	sd	hist	
1 Area	0	1	53048.	29324.		
2 Perimeter	0	1	855.	214.		
3 MajorAxisLength	0	1	320.	85.7		
4 MinorAxisLength	0	1	202.	45.0		
5 AspectRatio	0	1	1.58	0.247		
6 Eccentricity	0	1	0.751	0.0920		
7 ConvexArea	0	1	53768.	29775.		
8 EquivDiameter	0	1	253.	59.2		
9 Extent	0	1	0.750	0.0491		
10 Solidity	0	1	0.987	0.00466		
11 roundness	0	1	0.873	0.0595		
12 Compactness	0	1	0.800	0.0617		
13 ShapeFactor1	0	1	0.00656	0.00113		
14 ShapeFactor2	0	1	0.00172	0.000596		
15 ShapeFactor3	0	1	0.644	0.0990		
16 ShapeFactor4	0	1	0.995	0.00437		

Figura 10. Exploración de los datos con *skim* e histogramas de la distribución de los datos en cada variable.

De esta manera se puede suponer que los datos no cumplen con el supuesto de normalidad, pues la distribución de los datos en los histogramas no muestra ese comportamiento.

Para comprobar correlación de los datos y no habiendo rechazado la normalidad de los datos, se corrieron las pruebas de correlación paramétricas (Pearson) y no paramétricas (Spearman, Kendall).

```
# Correlación de los datos #
library(corrplot)
# Nivel de confiabilidad #
testRes <- cor.mtest(copy_dat7, conf.level = 0.95)

# Paramétrico (Pearson) #
P <- dat7 %>%
  select(where(is.numeric)) %>%
  cor()
round(P, 2)

corrplot(P, p.mat = testRes$p, method = 'circle', type = 'lower',
  insig='blank', tl.col = 'black', addCoef.col='black',tl.cex= .8,
  number.cex = 0.6, order = 'AOE', diag=FALSE,
  cl.ratio = 0.2, tl.srt = 45, col = COL2('PiYG', 10),number.font = 1.5)
title("Correlación de Pearson")
```



Figura 11. Coeficientes de correlación de Pearson.

```
# Spearmann #
R <- dat7 %>%
select(where(is.numeric)) %>%
cor(method = 'spearman')
round(R, 2)

corrplot(R, p.mat = testRes$p, method = 'circle', type = 'lower',
insig='blank', tl.col = 'black', addCoef.col='black',tl.cex= .8,
number.cex = 0.6, order = 'AOE', diag=FALSE,
cl.ratio = 0.2, tl.srt = 45, col = COL2('PiYG', 10),number.font = 1.5)
title("Correlación de Spearmann")
```




Figura 12. Coeficientes de correlación de Spearman.

```
# Kendall #
K <- dat7 %>%
  select(where(is.numeric)) %>%
  cor(method = 'kendall')
round(K, 2)

corrplot(K, p.mat = testRes$p, method = 'circle', type = 'lower',
  insig='blank', tl.col = 'black',
  addCoef.col='black',tl.cex= .8, number.cex = 0.6,
  order = 'AOE', diag=FALSE, cl.ratio = 0.2,
  tl.srt = 45, col = COL2('PiYG', 10),number.font = 1.5)
title("Correlación de Kendall")
```




Figura 13. Coeficientes de correlación de Kendall.

Para estos datos, las pruebas de correlación coinciden mostrando índices similares y comportamientos positivos negativos y positivos en las mismas variables, estas variables como: ConvexArea, EquivDiameter, Area, MajorAxisLength, AspectRatio y Eccentricity.

- b) Investigue que atributos pueden detectar mejor la diferencia entre variedades de frijol, use Kruskal Wallis o transformación a rangos de Conover $\alpha = 0,05$.

De acuerdo a los resultados anteriores las variables que mejor pueden detectar una diferencia entre las variedades de frijol son : ConvexArea, EquivDiameter, Area, MajorAxisLength, AspectRatio, Eccentricity y Perimeter.

Para conocer si existe una diferencia entre las variedades, para las pruebas se utilizara la variable "Perimeter", dado que muestra una mayor cantidad de correlación con las demas variables.

```
# Test de Kruskal-Wallis #
kruskal.test(Perimeter ~ Class, data = dat7)
```

Resultado:

```
Kruskal-Wallis rank sum test
```

```
data: Perimeter by Class
```

```
Kruskal-Wallis chi-squared = 11891, df = 6, p-value < 2.2e-16
```


Con un $\alpha = 0,5$, y un p-value de $<2.2e-16$ se confirma existen diferencias estadísticamente significativas entre las distintas variedades.

c) Realice las gráficas que apoyen su interpretación.

En la Figura 10, se puede evidenciar la diferencia entre las variedades, siendo la variedad *Bombay* la que obtuvo un valor alto en comparación a las demás variedades.

```
ggboxplot(dat7, x = "Class", y = "Perimeter",
color = "Class", palette = "jco",
ylab = "Perimeter", xlab = "Class",)+
geom_jitter(color="black", size=0.4, alpha=0.9)+
theme_pubr()
```




Figura 14. Variedades de Frijol respecto a la variable *Perimeter*.